

Homework #3

1. 46

将数据带入公式计算就行了。

2. [a][d][e]

假定 $N > d + 1$ 。

$X^T X$ 可逆 $\Leftrightarrow X$ 各列线性无关。

$H = X(X^T X)^{-1} X^T$ 是投影矩阵, H 将 N 维向量投影到 X 的列空间中, $HX = X$ 。

H 是实对称矩阵 $\Rightarrow H$ 可对角化 $\Leftrightarrow H$ 特征值的重数等于该特征值的线性无关的特征向量的个数。

综合上述定理, 可以推得:

H 有 $d + 1$ 个特征值为1。[d]正确

$HH = H$ 。[e]正确

H 是实对称矩阵 $\Rightarrow H$ 有 N 个正交的特征向量。其中, $d + 1$ 个特征向量的特征值是1, 它们都位于 X 的列空间中, 并可以生成 X 的列空间。那么, 其余的 $N - (d + 1)$ 个特征向量与 X 的列空间正交, 所以它们都是 H 特征值为0的特征向量。

综上, H 有 $d + 1$ 个特征值为1, $N - (d + 1)$ 个特征值为0。[a]正确

3. [a][b][e]

仿照Lecture11课件中那样画图, 就能看出来了。

4. [b][d][e]

5. 证明如下:

$$\text{err}(w) = \max(0, -yW^T x) = \begin{cases} -yW^T x, & yW^T x < 0 \\ 0, & yW^T x \geq 0 \end{cases}$$
$$\nabla_{w_t} \text{err}(w_t, x_n, y_n) = \begin{cases} -y_n x_n, & y_n W^T x_n < 0 \\ 0, & y_n W^T x_n \geq 0 \end{cases}$$

$$w_{t+1} = w_t + \eta [-\nabla_{w_t} \text{err}(w_t, x_n, y_n)] = \begin{cases} w_t + \eta y_n x_n, & y_n \neq \text{sign}(w^T x_n) \\ w_t, & y_n = \text{sign}(w^T x_n) \\ \text{或 } w^T x_n = 0 \end{cases}$$

6. $(-2, 0)$

7. 2.825

8. $(1.5, 4, -1, -2, 0, 3)$

9. 计算过程如下:

令

$$\begin{cases} \frac{\partial \hat{E}_2(\Delta u, \Delta v)}{\partial (\Delta u)} = 0 & = E_{uu}(u, v) \cdot (\Delta u) + E_{uv}(u, v) \cdot (\Delta v) + E_u(u, v) \\ \frac{\partial \hat{E}_2(\Delta u, \Delta v)}{\partial (\Delta v)} = 0 & = E_{vu}(u, v) \cdot (\Delta v) + E_{vv}(u, v) \cdot (\Delta u) + E_v(u, v) \end{cases}$$

记 $A_1 = E_{uu}(u, v)$, $A_2 = E_{uv}(u, v)$, $E_u(u, v) = A_3$,
 $B_1 = E_{vu}(u, v)$, $B_2 = E_{vv}(u, v)$, $E_v(u, v) = B_3$.
 $x = \Delta u$, $y = \Delta v$.

上式可表示为 $\begin{cases} A_1 x + A_2 y + A_3 = 0 \\ B_1 y + A_2 x + B_3 = 0 \end{cases}$, $\text{BP} \begin{bmatrix} A_1 & A_2 \\ A_2 & B_1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = - \begin{bmatrix} A_3 \\ B_3 \end{bmatrix}$.

由题可知 Hessian matrix 是正定矩阵, 所以 $\begin{bmatrix} A_1 & A_2 \\ A_2 & B_1 \end{bmatrix}$ 可逆.

$$\begin{bmatrix} x \\ y \end{bmatrix} = - \begin{bmatrix} A_1 & A_2 \\ A_2 & B_1 \end{bmatrix}^{-1} \begin{bmatrix} A_3 \\ B_3 \end{bmatrix} = - (\nabla^2 E(u, v))^{-1} \nabla E(u, v).$$

根据多元函数的极值相关定理, 可知 $\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} \Delta u \\ \Delta v \end{bmatrix} = - (\nabla^2 E(u, v))^{-1} \nabla E(u, v)$ 是最小值点。

• 参考资料:

- [Jacobian](#)矩阵和[Hessian](#)矩阵
- [使用牛顿法寻找极值](#)

10. 2.362

(五次迭代后, 用牛顿法得到的值更小, 说明牛顿法比梯度下降法速度更快。)

11. X1 X2 X3 X4 X5 X6

假设 $x = (x_1, x_2)$, 特征转换 $\Phi_2(x) = (1, x_1, x_2, x_1^2, x_1 x_2, x_2^2) = z$ 。

可求得:

$$\begin{aligned} \Phi_2(x_1) &= (1, 1, 1, 1, 1, 1) &= z_1 \\ \Phi_2(x_2) &= (1, 1, -1, 1, -1, 1) &= z_2 \\ \Phi_2(x_3) &= (1, -1, -1, 1, 1, 1) &= z_3 \\ \Phi_2(x_4) &= (1, -1, 1, 1, -1, 1) &= z_4 \\ \Phi_2(x_5) &= (1, 0, 0, 0, 0, 0) &= z_5 \\ \Phi_2(x_6) &= (1, 1, 0, 1, 0, 0) &= z_6 \end{aligned}$$

令

$$Z = \begin{bmatrix} z_1^T \\ z_2^T \\ z_3^T \\ z_4^T \\ z_5^T \\ z_6^T \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & -1 & 1 & -1 & 1 \\ 1 & -1 & -1 & 1 & 1 & 1 \\ 1 & -1 & 1 & 1 & -1 & 1 \\ 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 & 0 \end{bmatrix}, W = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \\ w_3 \\ w_4 \\ w_5 \end{bmatrix}$$

可求得 **Z可逆**。

令 $ZW = y$, 对于任意 $y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_6 \end{bmatrix}$, 都有 $W = Z^{-1}y$ 。那么, $z_1, z_2, z_3, z_4, z_5, z_6$ 可以被

shatter, 所以 $x_1, x_2, x_3, x_4, x_5, x_6$ 也可以被 **shatter**。

12. ∞

题中特征转换的意思是, 对于 **data** 中的任一 x ,

$$\Phi(x) = z = \begin{bmatrix} [x = x_1] \\ [x = x_2] \\ \vdots \\ [x = x_N] \end{bmatrix}$$

其中, $[x = x_n], n = 1, 2, \dots, N$ 的意思是: 若 $x = x_n$ 成立, 则值为 **1**, 否则为 **0**。

若 $x_i (i = 1, 2, \dots, N)$ 都不相同, 那么, $\Phi(x_1) = z_1 = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$,

$\Phi(x_2) = z_2 = \begin{bmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix}$, \dots , $\Phi(x_N) = z_N = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}$ 。

令 $Z = \begin{bmatrix} 1 & z_1^T \\ 1 & z_2^T \\ \vdots & \vdots \\ 1 & z_N^T \end{bmatrix}$, 可知 Z 的 **秩为N, 行满秩**。令 $ZW = y$, 对于任意 $y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$,

W 都有解。也就是说, z_1, z_2, \dots, z_N 可以被 **shatter**。所以, d_{vc} 是 ∞ 。

• 13-15: 编程题

16. 和 page 11 of Lecture 10 slides 的推导过程差不多, 相乘、取对数、加负号。

$$\text{likelihood}(w_1, \dots, w_k) \propto \prod_{n=1}^N h_{y_n}(x_n) = \prod_{n=1}^N \frac{\exp(W_{y_n}^T x_n)}{\sum_{i=1}^K \exp(W_i^T x_n)}$$

$$\begin{aligned} E_{\text{in}}(w_1, \dots, w_k) &= -\frac{1}{N} \ln \prod_{n=1}^N \frac{\exp(W_{y_n}^T x_n)}{\sum_{i=1}^K \exp(W_i^T x_n)} \\ &= \frac{1}{N} \sum_{n=1}^N \ln \frac{\sum_{i=1}^K \exp(W_i^T x_n)}{\exp(W_{y_n}^T x_n)} \\ &= \frac{1}{N} \sum_{n=1}^N \left[\ln \left(\sum_{i=1}^K \exp(W_i^T x_n) \right) - W_{y_n}^T x_n \right]. \end{aligned}$$

17.

$$\begin{aligned} \frac{\partial E_{\text{in}}}{\partial w_i} &= \frac{1}{N} \sum_{n=1}^N \left(\frac{\exp(w_i^T x_n)}{\sum_{i=1}^K \exp(w_i^T x_n)} x_n - [y_n = i] x_n \right) \\ &= \frac{1}{N} \sum_{n=1}^N ((h_i(x_n) - [y_n = i]) x_n) \end{aligned}$$

- 18-20: 编程题